SC 612 104

Data Preparation

การจัดการข้อมูล: จากข้อมูลดิบสู่ข้อมูลที่ใช้งานได้จริง

Data Preprocessing: Missing Data, Noise, Feature Engineering

อ.ดร.พิชญา วิรัชโชติเสถียร · ภาควิชาสถิติ คณะวิทยาศาสตร์ มข.

นิยามความผิดปกติ

Data Glitch: เมื่อข้อมูลเกิดข้อผิดพลาด (Bug/Error)

Data glitch คือข้อผิดพลาดหรือความผิดปกติที่เกิดขึ้นในข้อมูล มักหมายถึงค่าที่ผิดเพี้ยน ไม่สมเหตุสมผล หรือไม่สอดคล้องกับรูปแบบที่ควรจะเป็น โดยมักเกิดจากกระบวนการเก็บ บันทึก หรือส่งผ่านข้อมูล ไม่ใช่ความแปรปรวนทางธรรมชาติ

ตัวอย่างของ Glitches:

- **ค่าที่เป็นไปไม่ได้** : เช่น อายุ = -5 หรือ อายุ = 200 ปี
- **รูปแบบไม่สอดคล้อง** : เช่น วันที่ใช้ทั้ง `DD/MM/YYYY` และ `MM-DD-YYYY`
- **รหัสพิเศษแทนค่าว่าง** : เช่น ใส่ `-999`, `9999`, หรือ `"N/A"` ระบบเข้าใจผิดว่าเป็นตัวเลขจริง
- **ตัวอักษรปนตัวเลข** : เช่น ราคาสินค้าเป็น `"25.00zł"`
- **ค่าซ้ำซ้อน** : บันทึกหลายครั้งด้วยชื่อสะกดต่างกันเล็กน้อย
- **Encoding ผิดเพี้ยน** : ภาษาไทยกลายเป็นตัวอักษรประหลาด (Mojibake)
- **เซ็นเซอร์ขัดข้องชั่วครู่** : ทำให้ค่าที่บันทึกกระโดดผิดปกติแบบไม่ต่อเนื่อง (spike)

Data glitch ต่างจาก missing data หรือ noise ทั่วไป เพราะมักเป็นสัญญาณของ **"บั๊ก"** ในระบบเก็บข้อมูล

• ฟอร์มไม่มีการตรวจสอบ • โค้ดแปลงข้อมูลผิด • รวมข้อมูลไม่สอดคล้องกัน

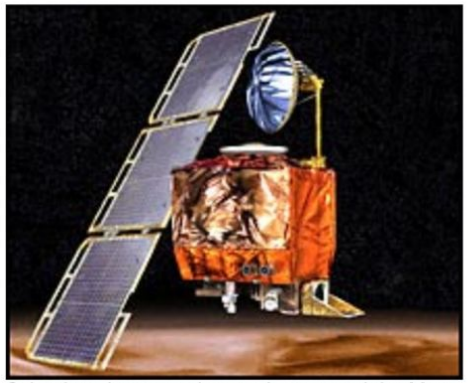
"การตรวจพบ glitch ตั้งแต่ต้นช่วยให้แก้ปัญหาที่ต้นเหตุ ไม่ใช่แค่ปลายทาง"

Did a data glitch ever destroy a spaceship!?

Mystery of Orbiter Crash Solved

By Kathy Sawyer
Washington Post Staff Writer
Friday, October 1, 1999; Page A1

NASA's Mars Climate Orbiter was lost in space last week because engineers failed to make a simple conversion from English units to metric, an embarrassing lapse that sent the $125 million craft fatally close to the Martian surface, investigators said yesterday.



Scientists do not yet know what caused the Mars Orbiter to crash. (AP)

CASE STUDY: MARS CLIMATE ORBITER

Mystery of Orbiter Crash Solved

NASA's Mars Climate Orbiter was lost because engineers failed to make a simple conversion from **English units to metric**.

An embarrassing $125 million lapse that sent the craft fatally close to the Martian surface.

Source: washingtonpost.com/wp-srv/national/longterm/space/stories/orbiter100199.htm



ก่อนเริ่ม ... ลองคิดดูสักครู่

คุณทำอย่างไรเมื่อเจอค่าที่ "หายไป" ในข้อมูล?

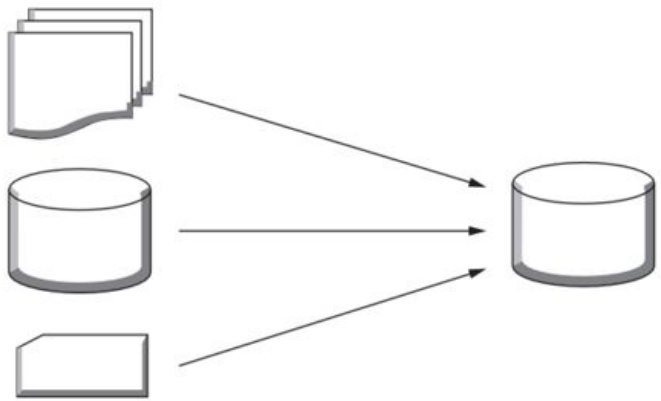
แบบสอบถามที่ไม่ตอบบางข้อ · เซ็นเซอร์ที่ขัดข้องชั่วครู่ · ระบบบล่มกลางบันทึกข้อมูล
โมเดลส่วนใหญ่ "รัน" ไม่ได้ ถ้าข้อมูลยังไม่สมบูรณ์ — นี่คือเหตุผลที่เราต้องเรียนเรื่องนี้

Data Preprocessing

Data Cleaning



Data Integration



Data Transformation –17, 25, 39, 128, –39 → 0.17, 0.25, 0.39, 1.28, –0.39

Data Reduction

	A1	A2	A3	....	A200
T1					
T2					
T3					
....					
T200					

→

	A1	A2	A3	...	A120
T1					
T2					
T3					
....					
T150					

Forms of data pre-processing (N.H. Son, Data Cleaning and Data Pre-processing[21]).

นิยาม

Data Preprocessing คืออะไร ?



1. Data Cleaning

- แก้ Missing Values: ข้อมูลที่ขาดหายไป
- แก้ Noisy Data: ข้อมูลที่มีสัญญาณรบกวน/ผิดพลาด
- แก้ Inconsistent Data: ข้อมูลที่ไม่สอดคล้องกัน



2. Integration · Reduction · Transformation

- Integration: รวมข้อมูลจากหลายแหล่งให้สอดคล้องกัน
- Reduction: ลดขนาดข้อมูลโดยคงสาระสำคัญ
- Transformation: ปรับรูปแบบให้พร้อมสำหรับโมเดล

ทำไมต้องเรียนเรื่องนี้

นี่คือทักษะที่ใช้เวลามากที่สุดในงานจริง

80%

ของเวลาทำงาน Data Scientist ใช้ไปกับการเตรียมข้อมูล

1 ใน 3

ของบันทึกในฐานข้อมูลจริง มักมีค่าผิดพลาดหรือขาดหาย

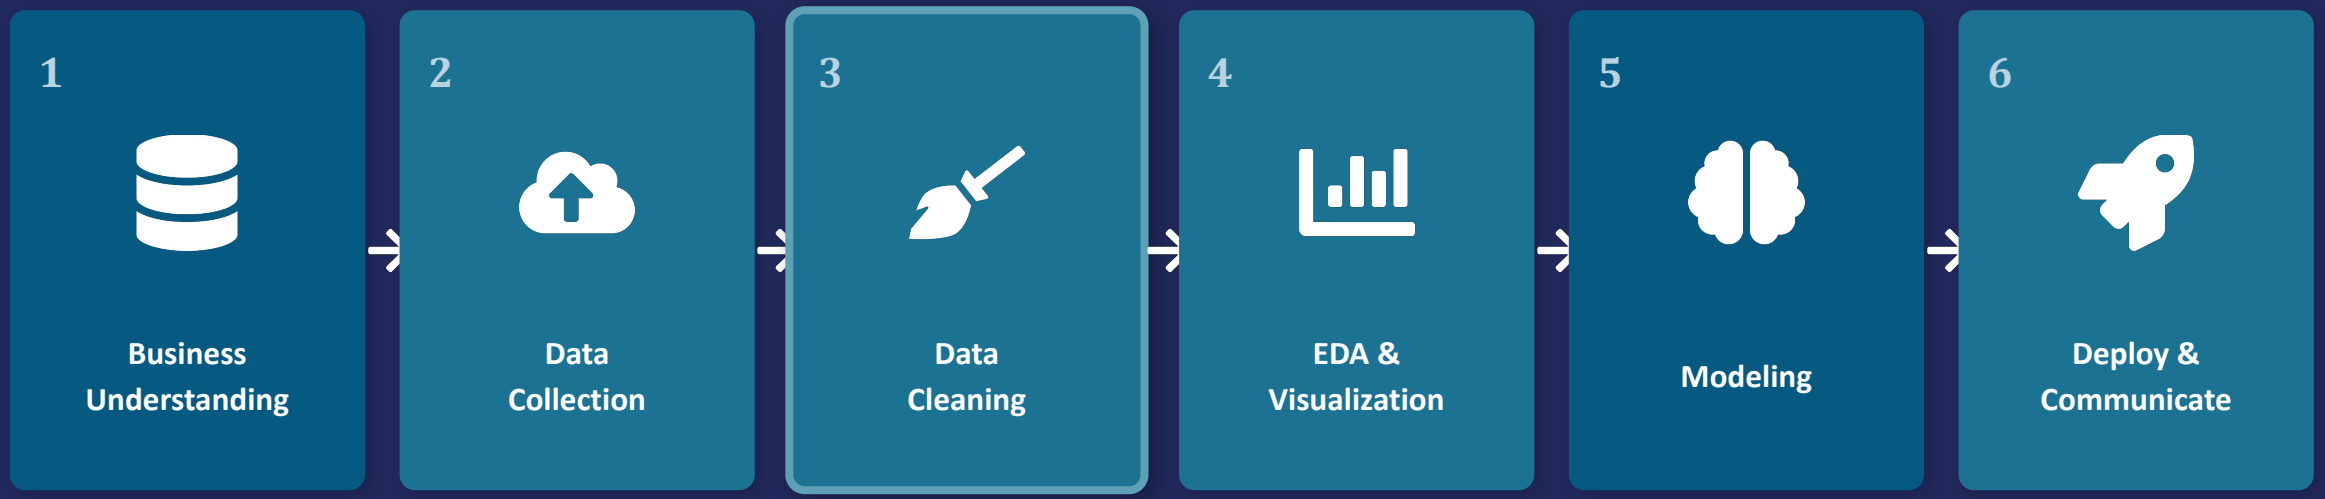
GIGO

Garbage In, Garbage Out — โมเดลดีแค่ไหนก็พังได้ ถ้าข้อมูลแย่

"ก่อนสอนโมเดลให้ฉลาด ต้องสอนข้อมูลให้สะอาดก่อน"

ทบทวน

วันนี้เราอยู่ที่ขั้นตอนที่ 3



วันนี้เราจะลงรายละเอียดขั้นตอนที่ 3 อย่างเต็มที่ — ก่อนไป EDA และ Modeling

ปัญหาของข้อมูลจริง

Real-World Data ไม่เคยสมบูรณ์แบบ



1. Incomplete (ข้อมูลไม่ครบ)

- ขาดค่าบางช่อง (missing attributes)
- ขาดบางบันทึกที่ควรมี (missing records)
- ขาดข้อมูลที่จำเป็นสำหรับการวิเคราะห์



2. Noisy (มีสิ่งรบกวน)

- มีค่าผิดพลาดหรือค่าผิดปกติ (errors/outliers)
- เกิดจากอุปกรณ์/เซ็นเซอร์/มนุษย์กรอกผิด
- ทำให้ pattern ที่แท้จริงถูกบดบัง

Inconsistent และทำไมต้องแก้ก่อน EDA



3. Inconsistent (ไม่สอดคล้องกัน)

- หน่วยต่างกัน เช่น cm ปนกับ inch
- รูปแบบวันที่/ตัวพิมพ์ไม่เป็นมาตรฐาน
- ข้อมูลซ้ำซ้อนจากหลายแหล่ง (duplicates)



ทำไมต้องแก้ก่อน EDA/Modeling

- EDA ที่ตั้งอยู่บนข้อมูลเสีย ให้ผลลัพธ์เสีย
- โมเดลเรียนรู้ pattern ผิดจาก noise/bias
- การตัดสินใจที่อิงผลลัพธ์ก็ผิดตามไปด้วย

Garbage In, Garbage Out (GIGO) — หลักการที่ขาดไม่ได้ในงาน Data Science

Missing Data
ข้อมูลที่ขาดหายไป


กลไกการขาดหาย


วิธีรับมือ


เทคนิคขั้นสูง

Missing Data คืออะไร ?



นิยาม

- ค่าที่ควรมีอยู่ แต่ไม่ถูกบันทึกไว้ในข้อมูล
- แสดงเป็น NaN, NULL, ค่าว่าง, หรือรหัสพิเศษ เช่น -999
- พบได้ในข้อมูลแทบทุกประเภท: แบบสอบถาม, เซ็นเซอร์, ฐานข้อมูล



ทำไมจึงเกิดขึ้น

- ผู้ตอบแบบสอบถามข้ามคำถามบางข้อ
- เซ็นเซอร์/อุปกรณ์ขัดข้องชั่วคราว
- ข้อผิดพลาดจากการรวมข้อมูลหลายแหล่ง (merge)

3 กลไกของการขาดหายข้อมูล



MCAR — Missing Completely At Random

- การขาดหายไม่เกี่ยวข้องกับค่าใดๆ ในข้อมูลเลย
- เช่น เซ็นเซอร์สุ่มขัดข้อง โดยไม่ขึ้นกับค่าที่วัด
- ลบแถวที่ขาด หรือ impute แบบง่าย ก็ยังไม่ทำให้ผลเอนเอียง



MAR — Missing At Random

- การขาดหายเกี่ยวข้องกับตัวแปรอื่นที่สังเกตได้
- เช่น นักธุรกิจที่โกงมักไม่ตอบคำถามเรื่องเสียภาษี
- ใช้ตัวแปรอื่นช่วยพยากรณ์ค่าที่ขาดได้อย่างแม่นยำขึ้น

MNAR — Missing Not At Random

กลไกที่ซับซ้อนและอันตรายที่สุด

- การขาดหายเกี่ยวข้องกับค่าของตัวแปรนั้นเอง (ที่เราไม่เห็น)
- เช่น ผู้มีรายได้สูงมาก หรือต่ำมาก มักไม่ตอบแบบสอบถามรายได้
- ผู้ป่วยอาการรุนแรงที่สุด อาจเสียชีวิตก่อนถูกบันทึกข้อมูลครบ
- ลบทิ้งหรือ impute แบบง่ายจะทำให้ผลลัพธ์ "เอนเอียง" (biased) อย่างมาก

สรุปเปรียบเทียบ 3 กลไก

MCAR: สุ่มแท้ๆ ไม่เกี่ยวกับค่าใด
MAR: เกี่ยวกับตัวแปรอื่นที่สังเกตได้
MNAR: เกี่ยวกับค่าของตัวแปรนั้นเองที่ขาดไป

ซับซ้อนขึ้นเรื่อย ๆ ตามลำดับ

MCAR, MAR, or MNAR?

- **MCAR (Missing Completely At Random)** — การขาดหายไม่เกี่ยวข้องกับค่าใด ๆ เลย ไม่ว่าจะเป็นค่าที่สังเกตได้หรือค่าที่ขาดไปเอง เป็นการสุ่มแท้ ๆ
- **MAR (Missing At Random)** — การขาดหายเกี่ยวข้องกับ**ตัวแปรอื่นที่สังเกตได้** ในข้อมูล เช่น อายุ แต่ไม่ได้เกี่ยวกับค่าของตัวมันเอง
- **MNAR (Missing Not At Random)** — การขาดหายเกี่ยวข้องกับ**ค่าของตัวแปรนั้นเอง** ค่าที่หายไปนั่นแหละเป็นเหตุผลที่มันหายไป

Case A

คนที่ตัวเตี้ยกว่า มีข้อมูลส่วนสูงที่ขาดหายไป

Case B

เด็กเล็กไม่มีข้อมูลส่วนสูงบันทึกไว้

Case C

ทุกคนที่ 5 ที่เข้ารับการทดสอบ ข้อมูลถูกทำลาย (shredded)

Missing Data · Challenge

MCAR, MAR, or MNAR?

- **MCAR (Missing Completely At Random)** — การขาดหายไม่เกี่ยวข้องกับค่าใด ๆ เลย ไม่ว่าจะเป็นค่าที่สังเกตได้หรือค่าที่ขาดไปเอง เป็นการสุ่มแท้ ๆ
- **MAR (Missing At Random)** — การขาดหายเกี่ยวข้องกับ**ตัวแปรอื่นที่สังเกตได้** ในข้อมูล เช่น อายุ แต่ไม่ได้เกี่ยวกับค่าของตัวมันเอง
- **MNAR (Missing Not At Random)** — การขาดหายเกี่ยวข้องกับ**ค่าของตัวแปรนั้นเอง** ค่าที่หายไปนั่นแหละเป็นเหตุผลที่มันหายไป

Case A

คนที่ตัวเตี้ยกว่า มีข้อมูลส่วนสูงที่ขาดหายไป

MNAR (Missing Not At Random)
เพราะการที่ข้อมูลส่วนสูงหายไปนั้นขึ้นอยู่กับค่าของตัวแปรนั้นเอง คือข้อมูลส่วนสูงของคนที่ตัวเตี้ยมักจะหายไป

Case B

เด็กเล็กไม่มีข้อมูลส่วนสูงบันทึกไว้

MAR (Missing At Random)
เพราะการที่ข้อมูลหายไปเกี่ยวข้องกับตัวแปรอื่นที่สังเกตได้ คือกลุ่มอายุหรือความเป็นเด็ก ไม่ได้เกิดจากตัวค่าความสูงโดยตรง

Case C

ทุกคนที่ 5 ที่เข้ารับการทดสอบ ข้อมูลถูกทำลาย (shredded)

MCAR (Missing Completely At Random)
เพราะเป็นการสุ่มทำลายข้อมูล (ทุกคนที่ 5) โดยไม่เกี่ยวข้องกับค่าใด ๆ ในข้อมูลเลย

4 แนวทางหลักในการรับมือ Missing Data

1. Deletion (การลบ)

ลบทั้งแถว (listwise) หรือทั้งคอลัมน์ — ใช้เมื่อขาดน้อยและเป็น MCAR เท่านั้น

2. Simple Imputation

แทนด้วย Mean / Median / Mode — เร็วแต่ลด variance ของข้อมูลลง

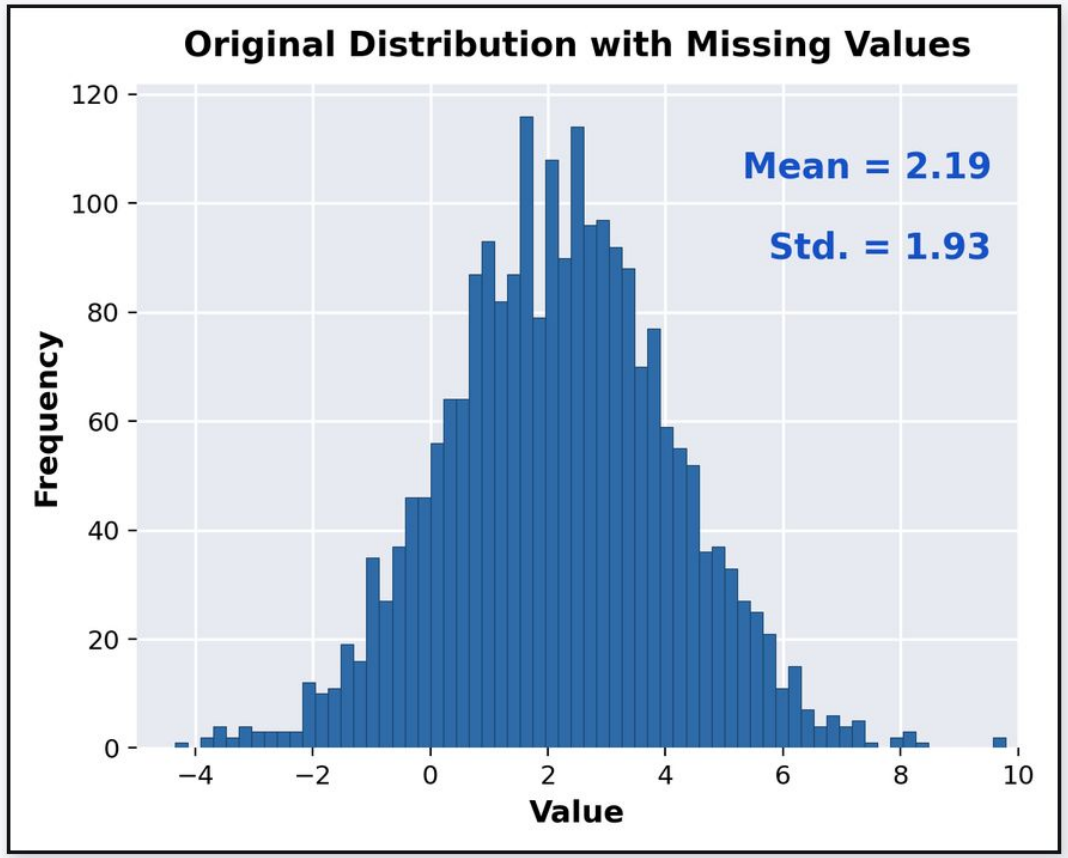
3. Model-Based Imputation

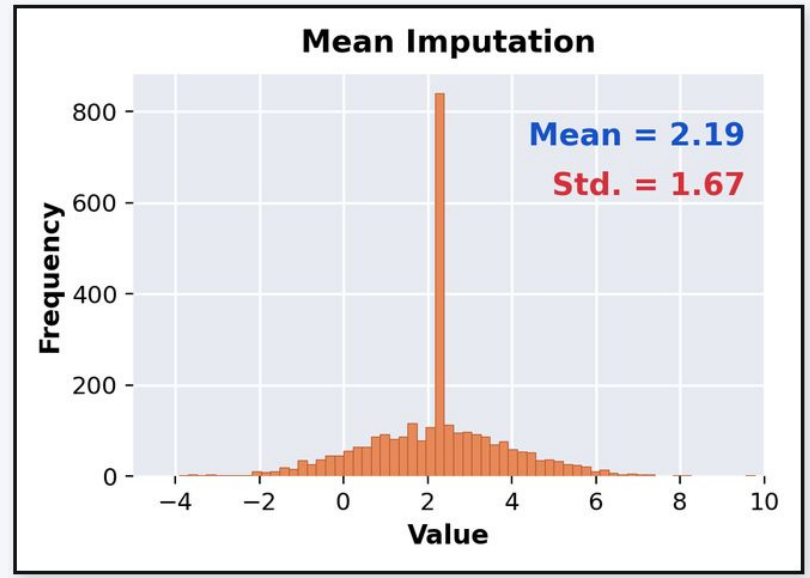
ใช้ Regression, KNN, MICE หรือ MissForest พยากรณ์ค่าที่ขาดจากตัวแปรอื่น

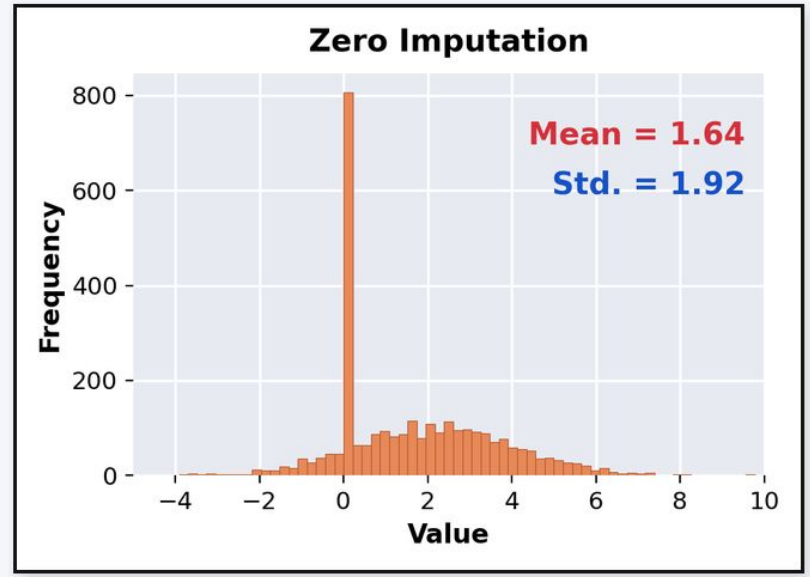
4. Missing Indicator

เพิ่มคอลัมน์ใหม่บอกว่า "ค่านี้ขาดหรือไม่" — เก็บข้อมูลว่าทำไมขาดไว้ใช้ต่อ

With Zero or Mean







Use model-based imputation (e.g., regression, MICE, KNN)

วิธีตัดสินใจเลือกกลยุทธ์ที่เหมาะสม

1	**Step 1: หาว่าขาดเท่าไร และขาดที่ไหน**	ตรวจสัดส่วน % missing ต่อคอลัมน์ และดู pattern ว่าขาดพร้อมกันหรือไม่
2	**Step 2: วินิจฉัยกลไก MCAR / MAR / MNAR**	ทดสอบความสัมพันธ์กับตัวแปรอื่น เพื่อแยกแยะกลไกการขาดหาย
3	**Step 3: เลือกวิธีรับมือที่เหมาะกับกลไกนั้น**	ขาดน้อย+MCAR → ลบได้ · ขาดมาก/ซับซ้อน → ใช้ Model-Based Imputation

MICE: Multiple Imputation by Chained Equations



เทคนิค imputation ที่ทรงพลังที่สุดในปัจจุบัน

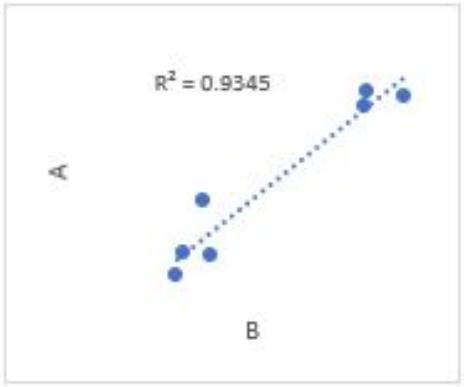
- สร้างหลาย dataset ที่เติมค่าต่างกัน แล้ว iterate ทีละตัวแปร
- ใช้ Regression model พยากรณ์ค่าที่ขาดจากตัวแปรอื่นซ้ำหลายรอบ
- MissForest: ใช้ Random Forest แทน Regression สำหรับข้อมูลซับซ้อน
- ให้ผลลัพธ์ที่แม่นยำกว่า mean/median imputation อย่างมีนัยสำคัญ

ทำไมต้องใช้เทคนิคขั้นสูง

Mean/Median Imputation ทำให้ variance ของข้อมูลลดลงและทำลายความสัมพันธ์ระหว่างตัวแปร ส่วน MICE/MissForest รักษาโครงสร้างความสัมพันธ์เหล่านี้ไว้ได้ดีกว่า

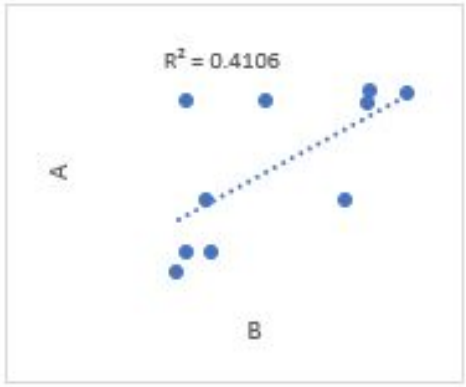
Missing data is in red. There is a strong correlation between A and B, so let's try to impute A using B and C.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
	0.80	
0.95	1.24	1.46
0.23	0.57	
0.90		1.28
0.15	0.42	
0.47	0.54	0.63
	1.14	
0.89	1.23	1.45



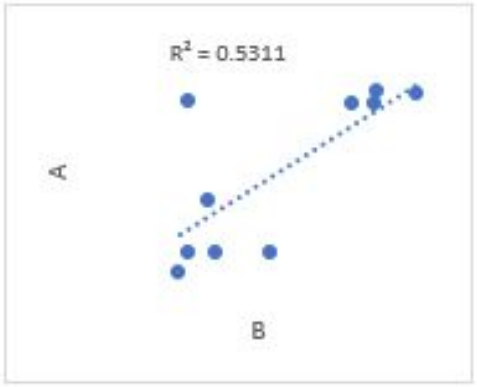
Missing data is filled in randomly. This dillutes the correlations, but allows us to impute using all available data.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.90	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.47	1.14	1.28
0.89	1.23	1.45



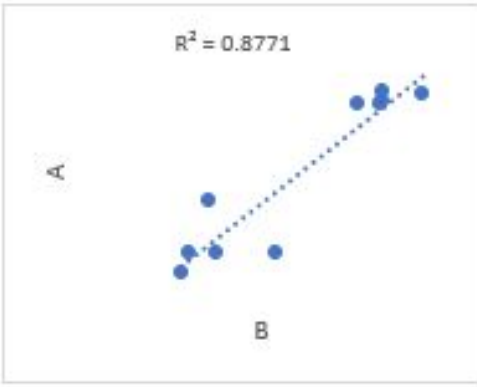
A random forest is used to predict A with B and C. Notice the correlation between A and B improved.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	0.46	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45

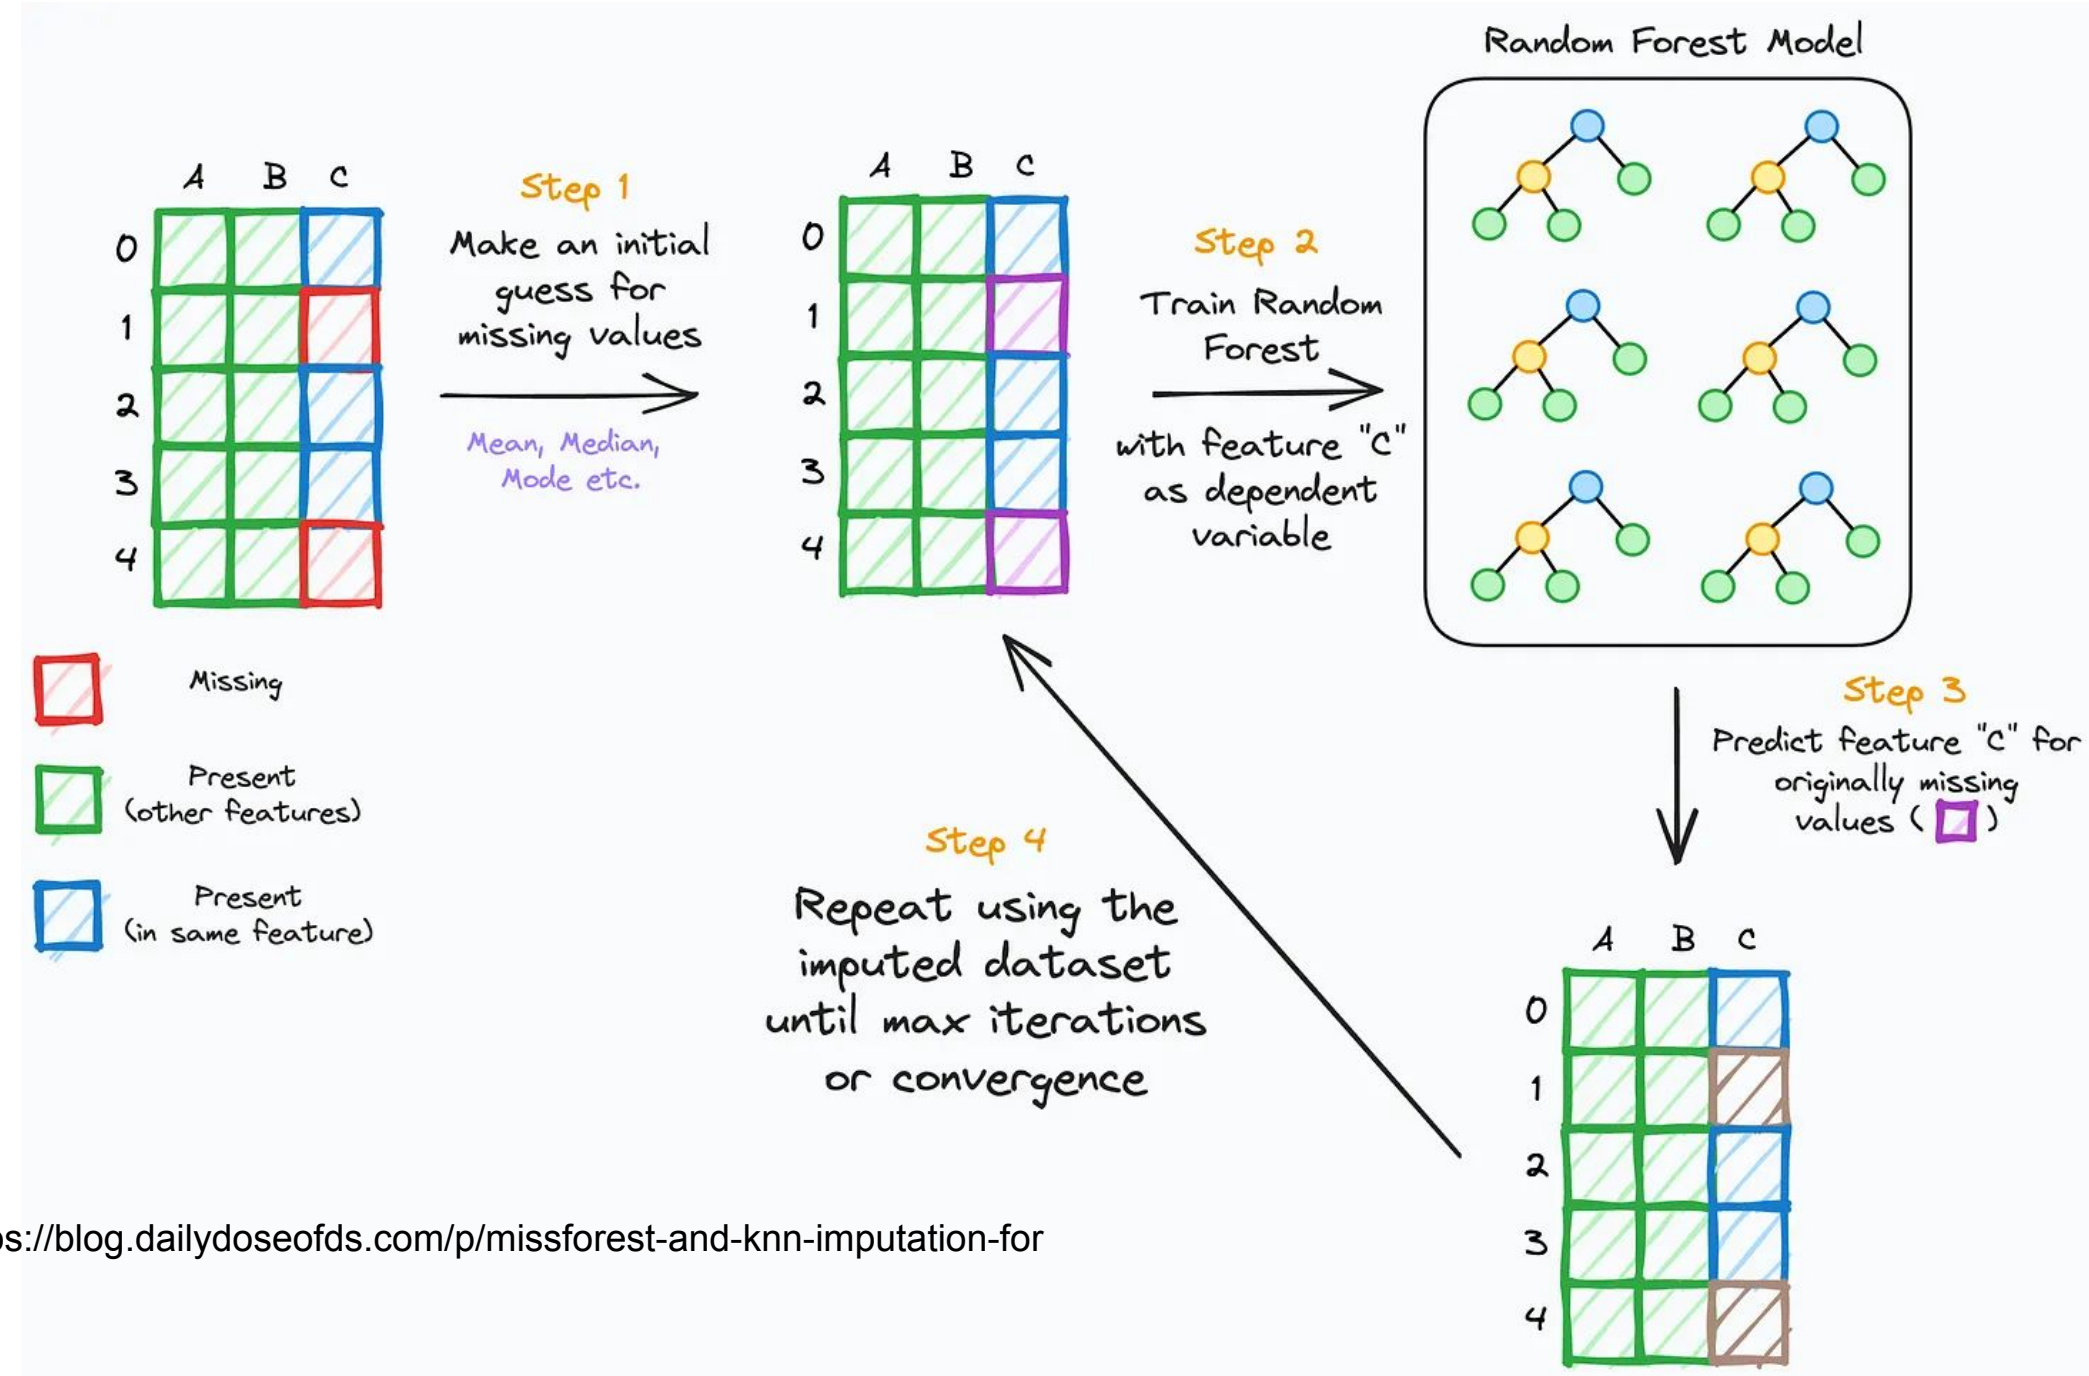


After Imputing B using A and C, we have achieved a correlation between A and B much closer to the original data.

A	B	C
0.93	1.40	1.53
0.24	0.46	0.76
0.24	0.80	1.53
0.95	1.24	1.46
0.23	0.57	1.28
0.90	1.24	1.28
0.15	0.42	1.53
0.47	0.54	0.63
0.89	1.14	1.28
0.89	1.23	1.45



https://github.com/AnotherSamWilson/miceforest?tab=readme-ov-file#the-mice-algorithm



https://blog.dailydoseofds.com/p/missforest-and-knn-imputation-for

Missing Indicators

การสร้างตัวบ่งชี้ค่าที่สูญหายเพื่อรักษารูปแบบข้อมูล

แนวคิดหลัก (The Concept)

เป็นการสร้างฟีเจอร์ใหม่ประเภท Binary (0 หรือ 1) เพื่อบันทึกสถานะว่าข้อมูลในแถวนั้นๆ เคยเป็นค่าว่าง (Missing) มาก่อนหรือไม่ ก่อนที่เราจะทำการแทนที่ค่าว่างเหล่านั้นด้วยวิธีอื่น ๆ เช่น Mean หรือ Median Imputation

- **ป้องกันการสูญเสียข้อมูลเชิงโครงสร้าง : บางครั้งการที่ข้อมูลหายไป (Missingness) มีนัยสำคัญในตัวเอง เช่น ผู้ใช้จงใจไม่กรอกข้อมูล**
- **ช่วยโมเดลแยกแยะ : โมเดลจะรับรู้ได้ว่าค่าที่ถูกแทนที่ (Imputed Value) นั้นเดิมทีเป็นค่าจริงหรือค่าที่ถูกสร้างขึ้นใหม่**
- **ใช้งานง่ายในรูปแบบ Code: `MissingIndicator` ใน Scikit-Learn**

Feature 1	Feature 2
18.91	14.25
13.42	—
—	2.5
4.06	—

⟶

Feature 1	Feature 2	Indicator 1	Indicator 2
18.91	14.25	0	0
13.42	0	0	1
0	2.5	1	0
4.06	0	0	1

💡 เทคนิคนี้มักใช้ควบคู่กับ `SimpleImputer` เพื่อสร้างฟีเจอร์ใหม่ที่มีประสิทธิภาพสูงสุดในเชิงทำนาย

💡 **คำถามชวนคิด :ถ้าสร้างตัวแปรใหม่ที่เป็น binary แล้ว จะเติมค่าตัวแปรเก่าด้วยอะไรดี?**

แนะนำให้เติมด้วยค่าคงที่ที่ปลอดภัย (เช่น 0, Mean, Median) เพราะมีตัวบ่งชี้สีส้ม/บีคอน (Binary Indicator) คอยแจ้งโมเดลอยู่แล้ว

ส่วนที่ 2

Noise & Outliers
สิ่งรบกวนและค่าผิดปกติ


Noise คืออะไร


วิธี Smoothing


Outlier Detection



Source: quora.com/How-do-I-distinguish-outlier-and-noise-in-a-data-set

Noisy Data คืออะไร ?



นิยาม

- ค่าที่มีความผิดพลาดสุ่ม หรือเบี่ยงเบนจากค่าจริง
- ปกปิด pattern ที่แท้จริงของข้อมูล ทำให้วิเคราะห์ผิดพลาด
- ต่างจาก Missing Data — Noise มีค่าอยู่ แต่ค่านั้น "ไม่ถูกต้อง"



แหล่งที่มาของ Noise

- ความผิดพลาดของอุปกรณ์/เซ็นเซอร์วัด (instrument error)
- มนุษย์กรอกข้อมูลผิด หรือพิมพ์ตัวเลขสลับหลัก
- ข้อผิดพลาดจากการส่งผ่าน/แปลงไฟล์ (transmission error)

Binning & Regression Smoothing



Binning (การจัดกลุ่มเป็นช่วง)

- แบ่งข้อมูลเป็นช่วง (bins) แล้วแทนค่าด้วยค่าตัวแทนของช่วง
- Smoothing by mean: แทนทุกค่าในช่วงด้วยค่าเฉลี่ยของช่วง
- Smoothing by median/boundary: ลดผลกระทบจากค่าสุดขั้ว



Regression (การถดถอย)

- หาฟังก์ชันที่เหมาะสมเพื่อ fit ข้อมูลให้เป็นเส้นเรียบ
- Linear/Polynomial Regression ช่วยพยากรณ์ค่าที่ควรจะเป็น
- ค่าที่เบี่ยงเบนจากเส้น fit มาก ถือเป็นสัญญาณของ noise

ตรวจจับและจัดการค่าผิดปกติ

วิธีตรวจจับ Outlier

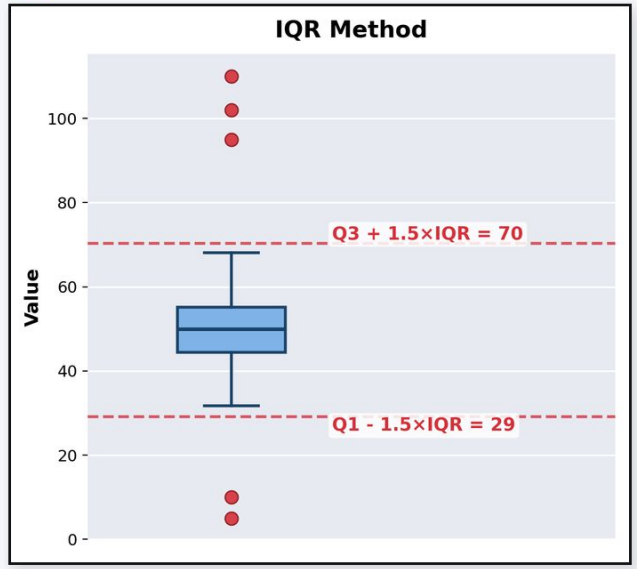
- IQR Method: ค่านอกช่วง [Q1-1.5IQR, Q3+1.5IQR] ถือเป็น outlier
- Z-score: ค่าที่ห่างจากค่าเฉลี่ยมากกว่า 3 ส่วนเบี่ยงเบนมาตรฐาน
- Visualization: Boxplot และ Scatter plot ช่วยมองเห็นได้ชัดเจน
- Isolation Forest/DBSCAN: สำหรับข้อมูลมิติสูงและซับซ้อน

เจอ Outlier แล้วทำอย่างไร ?

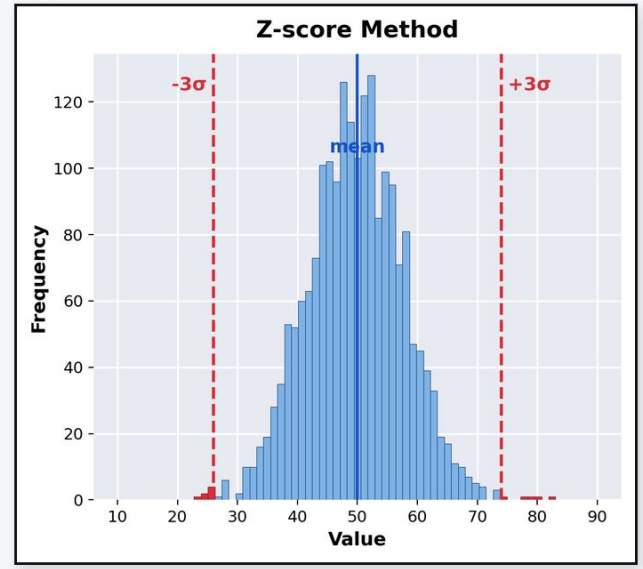
ไม่ใช่ Outlier ทุกตัวที่ต้องลบ! ตรวจสอบก่อนว่าเป็นข้อผิดพลาดจริง หรือเป็นเหตุการณ์หายาก เช่น ยอดขายพุ่งช่วงโปรโมชัน ที่มีความหมายทางธุรกิจ

Outlier Detection Methods

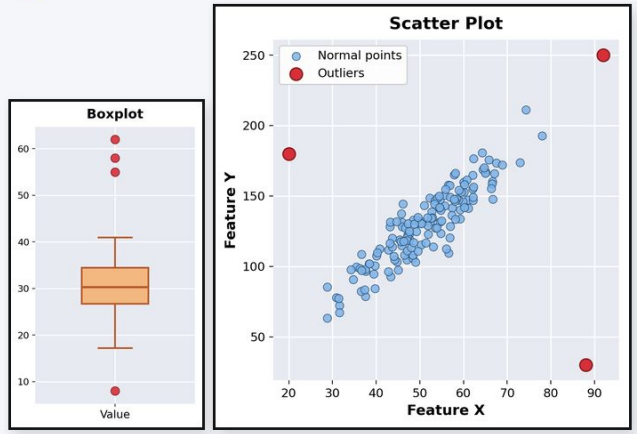
1 ค่านอกช่วง [Q1-1.5×IQR, Q3+1.5×IQR] ถือเป็น outlier



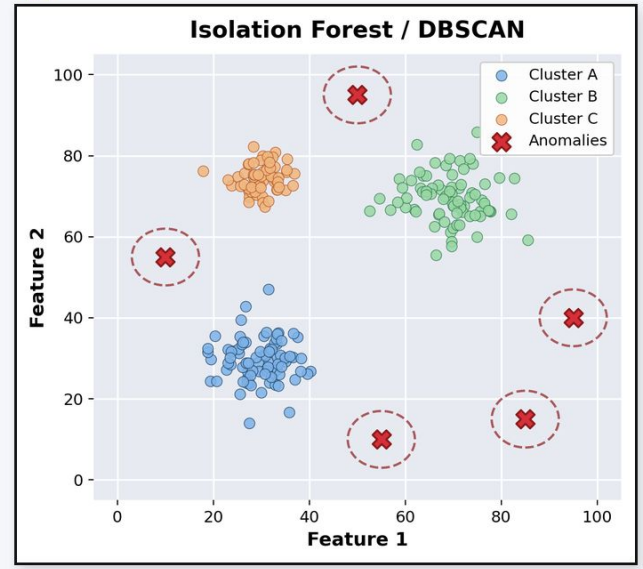
2 ค่าที่ห่างจากค่าเฉลี่ยมากกว่า 3 ส่วนเบี่ยงเบนมาตรฐาน



3 Boxplot และ Scatter plot ช่วยมองเห็นได้ชัดเจน



4 สำหรับข้อมูลมิติสูงและซับซ้อน



การจัดการกับ outlier

1. นำออก (Remove)

หากตรวจสอบแล้วว่าเป็นข้อผิดพลาดในการบันทึกข้อมูล (Error) และไม่สามารถแก้ไขได้ การนำข้อมูลนั้นออกอาจเป็นทางเลือกที่ปลอดภัยที่สุด

2. แปลงข้อมูล (Transform)

นิยมใช้ **log transform** เพื่อลดความเบ้ของข้อมูล และบีบช่วงของค่าสุดขั้วให้เข้าใกล้ค่าอื่นๆ มากขึ้น

3. ตัดส่วนปลาย (Trim)

การนำข้อมูลส่วนปลาย (Trimming) ออกในสัดส่วนที่กำหนด เช่น ตัดค่าสูงสุดและต่ำสุดออก 5% เพื่อให้ได้ข้อมูลที่สะท้อน
ค่าส่วนใหญ่

Integration · Reduction
Transformation · Feature Engineering



รวมข้อมูลหลายแหล่ง



ลดและแปลงข้อมูล



สร้างตัวแปรใหม่

รวมข้อมูลจากหลายแหล่งให้สอดคล้องกัน

1	**Schema Integration (ความขัดแย้งของโครงสร้าง)**	ชื่อคอลัมน์ต่างกันแต่หมายถึงสิ่งเดียวกัน เช่น "cust_id" vs "customer_id"
2	**Value Conflict (ความขัดแย้งของค่า)**	หน่วยวัดต่างกัน (กก. vs ปอนด์) หรือมาตราส่วนต่างกัน (0-100 vs 0-10)
3	**Redundancy (ความซ้ำซ้อน)**	ตัวแปรที่ซ้ำกันหรืออนุมานได้จากตัวแปรอื่น ตรวจด้วย correlation analysis

Reduction & Transformation

ลดขนาดและแปลงรูปแบบข้อมูล



Data Reduction

- Dimensionality Reduction: PCA ลดจำนวนตัวแปร
- Sampling: สุ่มตัวอย่างจากข้อมูลขนาดใหญ่
- Feature Selection: เลือกตัวแปรที่สำคัญที่สุด



Data Transformation

- Normalization/Standardization: ปรับช่วงค่าให้เทียบกันได้
- Discretization: แปลงตัวแปรต่อเนื่องเป็นหมวดหมู่
- Encoding: แปลงตัวแปรหมวดหมู่เป็นตัวเลข (One-Hot, Label)

ก้าวต่อจาก Cleaning

Feature Engineering: สร้างตัวแปรใหม่

Domain Knowledge Features

ใช้ความรู้เฉพาะด้าน เช่น BMI = น้ำหนัก/ส่วนสูง²

Interaction Features

รวมตัวแปรสองตัวเข้าด้วยกัน เช่น ราคา × จำนวน = ยอดขาย

Time-Based Features

ดึงวัน/เดือน/ฤดูกาล จาก timestamp หรือคำนวณ rolling average

Aggregation Features

สรุปค่าจากกลุ่ม เช่น ยอดซื้อเฉลี่ยต่อลูกค้าในแต่ละเดือน

Feature Engineering

ประเภทข้อมูลและการจัดการข้อมูล

Ratio & Interval

ตัวอย่าง :

Height, weight, number of people, etc.

การจัดการ :

- Scaling

Ordinal

ตัวอย่าง :

Grades: A, B, C, D
Preference: Like, Neutral, Dislike

การจัดการ :

- Numerical encoding

Nominal

ตัวอย่าง :

แบรนด์รถ Toyota, Tesla, Ford
ชื่อจังหวัด ขอนแก่น อุดรธานี กรุงเทพ

การจัดการ :

- One-hot encoder

Ratio & Interval Data

Ratio & Interval

Has a natural ordering with distance

ตัวอย่าง :

Height, weight, number of people, etc.

การจัดการ :

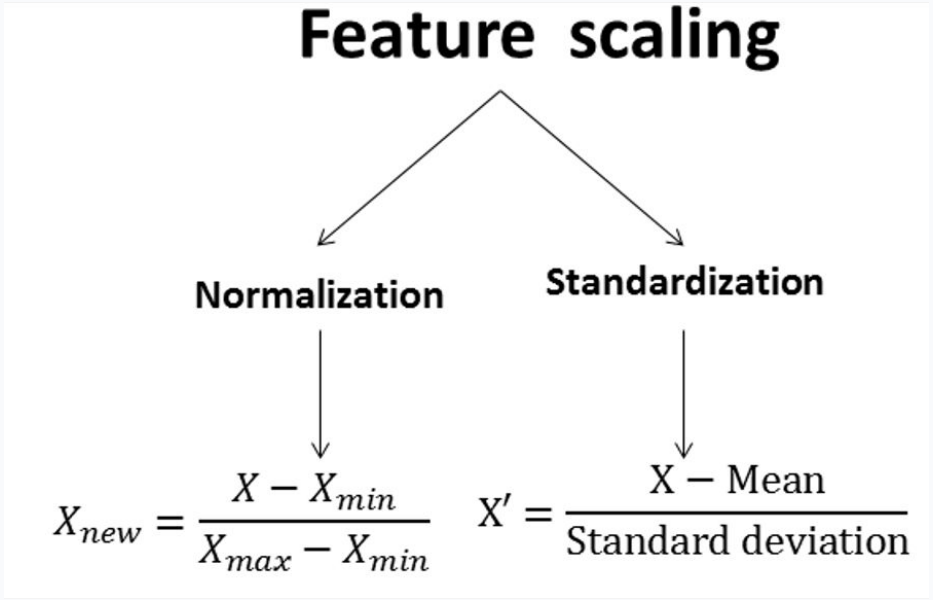
- **Scaling**

Transforming features to a common scale to prevent dominance by large-magnitude variables

Height	Weight
6 ft 2 inches	185 lbs
5 ft 2 inches	135 lbs
6 ft 3 inches	220 lbs
6 ft 0 inches	200 lbs
5 ft 9 inches	180 lbs



Height	Weight
6.17 ft	185 lbs
5.17 ft	135 lbs
6.25 ft	220 lbs
6.00 ft	200 lbs
5.75 ft	180 lbs



Ordinal Data

Ordinal

Has a natural ordering without distance

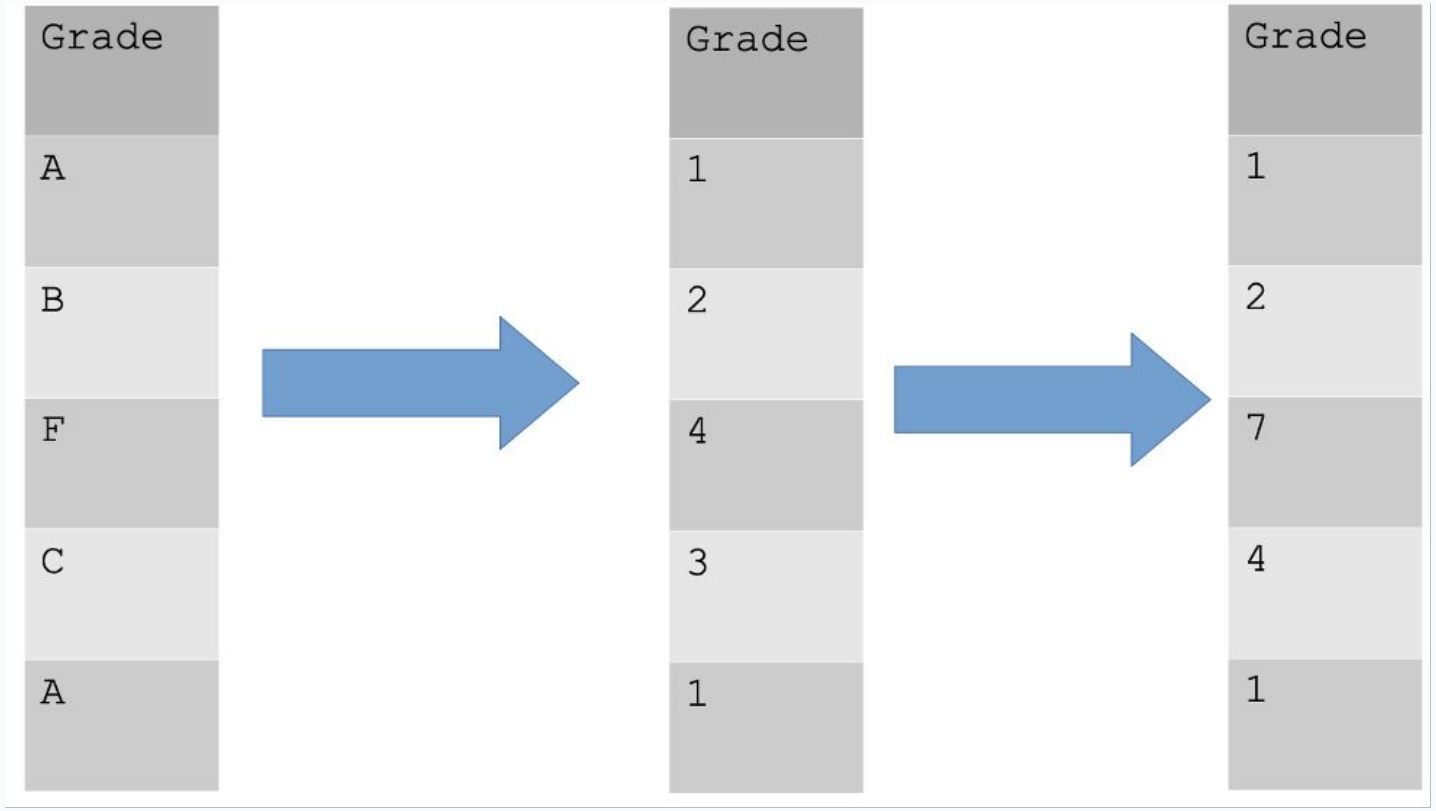
ตัวอย่าง :

Grades: A, B, C, D

Preference: Like, Neutral, Dislike

การจัดการ :

- **Numerical encoding**



Nominal Data

Nominal

No natural ordering

ตัวอย่าง :

แบรนด์รถ Toyota, Tesla, Ford
ชื่อจังหวัด ขอนแก่น อุดรธานี กรุงเทพ

การจัดการ :

- **One-hot encoder**

Car	Ford	Subaru	Toyota
Ford	1	0	0
Subaru	0	1	0
Toyota	0	0	1
Ford	1	0	0
Toyota	0	0	1

กิจกรรมกลุ่ม



หมอข้อมูล : วินิจฉัยข้อมูลเสีย

แบ่งกลุ่ม 3-4 คน รับตัวอย่างข้อมูล (CSV) ที่มีปัญหาซ่อนอยู่หลายแบบ

1. ตรวจหา missing values, noise, และ inconsistency ในข้อมูล (10 นาที)
2. ระบุกลไกการขาดหาย (MCAR/MAR/MNAR) และเลือกวิธีรับมือที่เหมาะสม
3. เตรียมนำเสนอแผนการแก้ไขข้อมูลสั้นๆ 2 นาที ถ้าเวลาเหลือ

สรุปคาบนี้

วันนี้เราทำอะไรไปบ้าง

- เข้าใจ Missing Data: กลไก MCAR/MAR/MNAR และวิธีรับมือแต่ละแบบ
- จัดการ Noise & Outliers ด้วย Binning, Regression, IQR, Z-score
- รู้จัก Data Integration, Reduction, และ Transformation
- สร้างตัวแปรใหม่ด้วยเทคนิค Feature Engineering 4 ประเภท

การบ้าน / เตรียมตัวคาบหน้า

- ฝึกทำ Data Cleaning กับ dataset ที่มีปัญหาจริงด้วย pandas
- ส่ง Worksheet กิจกรรมกลุ่ม (ถ้ายังไม่ส่งในคาบ)

กิจกรรมกลุ่ม — วินิจฉัยข้อมูลเสีย

กลุ่มที่ _____ สมาชิก: _____

1. ตรวจหาปัญหา : พบ Missing / Noise / Inconsistent ที่คอลัมน์ไหนบ้าง ?

1) _____

2) _____

3) _____

2. วินิจฉัยกลไก : ค่าที่ขาดหายเป็น MCAR / MAR / MNAR? เพราะอะไร ?

3. เสนอวิธีรักษา : เลือกวิธีรับมือที่เหมาะกับแต่ละปัญหา และอธิบายเหตุผล

ไม่มีคำตอบผิด เป้าหมายคือฝึกวินิจฉัยปัญหาข้อมูลให้เป็น

กรณี 1: การประมาณรายได้ครัวเรือน

บริบท (Context)

ทีมวิจัยเก็บแบบสอบถามภาวะเศรษฐกิจครัวเรือนในจังหวัดหนึ่ง จำนวน 5,000 ชุด เพื่อประมาณรายได้เฉลี่ยของครัวเรือนและนำไปเสนอเป็นข้อมูลประกอบการจัดสรรงบประมาณ

resp_id	age	education	occupation	monthly_income
1001	34	ปริญญาตรี	พนักงานบริษัท	28,000
1002	51	ปริญญาโท	เจ้าของกิจการ	(ว่าง)
1003	27	มัธยมปลาย	รับจ้างทั่วไป	9,500
1004	45	ปริญญาเอก	ผู้บริหาร	(ว่าง)
1005	62	ประถมศึกษา	เกษตรกร	6,200

ข้อมูลเพิ่มเติม (Key Findings)

คอลัมน์ `monthly_income` ขาดหายร้อยละ 23 และเมื่อดูรายอาชีพพบว่าสัดส่วนการขาดหายในกลุ่มผู้บริหารและเจ้าของกิจการสูงกว่ากลุ่มอื่นอย่างชัดเจน

❓ คำถามเฉพาะกลุ่ม

หากทีมวิจัยเลือกลบทุกแถวที่ไม่มีรายได้ทิ้งแล้วรายงานค่าเฉลี่ยจากข้อมูลที่เหลือ ตัวเลขที่รายงานจะสูงเกินจริงหรือต่ำกว่าจริง และจะกระทบต่อการจัดสรรงบประมาณอย่างไร

กรณี 2: เซ็นเซอร์วัดอุณหภูมิในโรงงานทำงานผิดปกติเป็นช่วง

บริบท (Context)

โรงงานติดตั้งเซ็นเซอร์วัดอุณหภูมิเตาเผาทุก 1 นาที เพื่อสร้างระบบแจ้งเตือนล่วงหน้าเมื่อเตาร้อนเกินกำหนด

timestamp	sensor_id	temp_c	status_code
2026-03-01 08:00	S-01	812.4	OK
2026-03-01 08:01	S-01	813.1	OK
2026-03-01 08:02	S-01	-999	ERR
2026-03-01 08:03	S-01	4521.8	OK
2026-03-01 08:04	S-01	814.0	OK
2026-03-01 08:05	S-01	(ว่าง)	(ว่าง)

ข้อมูลเพิ่มเติม (Key Findings)

เตาเผารุ่นนี้ทำงานในช่วง 700 ถึง 900 องศาเซลเซียส และคู่มือระบุว่าเมื่อเซ็นเซอร์อ่านค่าไม่ได้ ระบบจะบันทึกเป็น -999

❓ คำถามเฉพาะกลุ่ม

ค่า -999 กับค่า 4521.8 ควรจัดการต่างกันหรือไม่ และหากนำข้อมูลนี้ไปคำนวณค่าเฉลี่ยเคลื่อนที่เพื่อแจ้งเตือน จะเกิดผลอย่างไรหากไม่จัดการก่อน

กรณี 3: หน่วยวัดปนกันจากการรวมข้อมูลสองโรงพยาบาล

บริบท (Context)

โครงการวิจัยรวมข้อมูลผู้ป่วยจากโรงพยาบาลสองแห่ง เพื่อสร้างแบบจำลองทำนายความเสี่ยงโรคหัวใจ โดยใช้ค่าดัชนีมวลกายเป็นตัวแปรสำคัญ

patient_id	hospital	height	weight	bmi
A-001	รพ. ก	170	65	22.5
A-002	รพ. ก	158	52	20.8
B-101	รพ. ข	5.6	143	22.4
B-102	รพ. ข	6.1	198	26.1
B-103	รพ. ข	165	70	25.7

ข้อมูลเพิ่มเติม (Key Findings)

โรงพยาบาล ก บันทึกส่วนสูงเป็นเซนติเมตรและน้ำหนักเป็นกิโลกรัม ส่วนโรงพยาบาล ข บันทึกเป็นฟุตและปอนด์ แต่บางแถวของโรงพยาบาล ข กลับบันทึกเป็นหน่วยเมตริก

❓ คำถามเฉพาะกลุ่ม

ให้ออกแบบขั้นตอนตรวจจับหน่วยที่ปนกันโดยอัตโนมัติ โดยไม่ต้องอาศัยการดูด้วยตาทีละแถว และเชื่อมโยงกับกรณี Mars Climate Orbiter ว่าบทเรียนคืออะไร

กรณี 4: รูปแบบวันที่ไม่เป็นมาตรฐานในระบบขายออนไลน์

บริบท (Context)

ร้านค้าออนไลน์ต้องการวิเคราะห์ยอดขายรายเดือนและหาช่วงเวลาที่ลูกค้าสั่งซื้อมากที่สุด โดยดึงข้อมูลจากระบบหน้าร้านและระบบแอปพลิเคชันมารวมกัน

order_id	order_date	channel	amount
88001	03/04/2026	web	1,250
88002	2026-04-03	app	890
88003	4/3/2026	web	2,100
88004	03-04-2026 14:22	app	640
88005	2026/04/03	store	1,980

ข้อมูลเพิ่มเติม (Key Findings)

ระบบแอปพลิเคชันบันทึกเวลาเป็น UTC ส่วนระบบหน้าร้านบันทึกเป็นเวลาประเทศไทย และไม่มีคอลัมน์ใดระบุเขตเวลาไว้

❓ คำถามเฉพาะกลุ่ม

ยอดขายของวันที่ 1 และวันสุดท้ายของเดือนจะได้รับผลกระทบจากปัญหาเขตเวลาอย่างไร และหากต้องเลือกใช้ค่าเริ่มต้นในการแปลงวันที่ทั้งชุด ควรตั้งกฎอย่างไรจึงจะปลอดภัยที่สุด

กรณี 5: ลูกค้าคนเดียวกันถูกบันทึกซ้ำหลายรายการ

บริบท (Context)

ฝ่ายการตลาดต้องการนับจำนวนลูกค้าที่ซื้อซ้ำ และคำนวณยอดซื้อเฉลี่ยต่อลูกค้าหนึ่งราย จากฐานข้อมูลที่รวมจากระบบสมาชิกและระบบขายหน้าร้าน

cust_id	name	phone	email	total_spend
C-1001	สมชาย ใจดี	081-234-5678	somchai@mail.com	12,400
C-1055	สมชาย ใจดี	0812345678	Somchai@mail.com	8,700
C-1210	ส. ใจดี	081-234-5678	(ว่าง)	3,200
C-1330	สมหญิง ใจงาม	089-111-2222	somying@mail.com	15,600
C-1331	สมหญิง ใจงาม	089-111-2222	somying@mail.com	15,600

❓ คำถามเฉพาะกลุ่ม

ให้แยกให้ชัดระหว่างข้อมูลซ้ำแบบตรงกันทุกคอลัมน์ กับข้อมูลซ้ำที่เป็นบุคคลเดียวกันแต่บันทึกต่างกัน แล้วเสนอกฎการตัดสินว่าสองแถวใดคือคนเดียวกัน พร้อมระบุความเสี่ยงของกฎที่เข้มเกินไปและหลวมเกินไป

กรณี 6: ข้อมูลภาษาไทยเพี้ยนและตัวเลขปนตัวอักษร

บริบท (Context)

ทีมวิเคราะห์ได้รับไฟล์ข้อมูลสินค้าจากคู่ค้าต่างประเทศ เพื่อนำมารวมกับข้อมูลราคาในระบบของบริษัท

sku	product_name	price	qty	category
P-01	à¸à¸²à¹à¸Ÿà¸„ัว	25.00zł	12	เครื่องดื่ม
P-02	ชาเขียว	30 บาท	8	เครื่องดื่ม
P-03	ขนมปัง	45.50	5	Bakery
P-04	à¸à¸™à¸¡à¸›à¸±	45.50	5	bakery
P-05	นมสด	1,250.00	3	เครื่องดื่ม

❓ คำถามเฉพาะกลุ่ม

ปัญหาในตารางนี้มีอย่างน้อยสี่ชนิดที่แตกต่างกัน ให้ระบุให้ครบ แล้วจัดลำดับว่าควรแก้ปัญหาใดก่อนหลัง พร้อมอธิบายว่าเหตุใดลำดับการแก้จึงสำคัญ

กรณี 7: ค่าผิดปกติที่อาจไม่ใช่ความผิดพลาด

บริบท (Context)

ทีมวิเคราะห์ยอดขายของห้างสรรพสินค้าเตรียมข้อมูลรายวันตลอดหนึ่งปี เพื่อสร้างแบบจำลองพยากรณ์ยอดขายล่วงหน้า 30 วัน

date	branch	daily_sales	n_transactions	note
2025-11-09	สาขา A	1,240,000	3,120	
2025-11-10	สาขา A	1,180,000	2,980	
2025-11-11	สาขา A	9,850,000	21,400	แคมเปญ 11.11
2025-11-12	สาขา A	1,310,000	3,290	
2025-12-25	สาขา A	4,200,000	9,850	
2026-01-14	สาขา A	62,000	141	ไฟฟ้าดับ

❓ คำถามเฉพาะกลุ่ม

ค่าผิดปกติในตารางนี้ไม่ควรจัดการด้วยวิธีเดียวกันทั้งหมด ให้จำแนกว่าแถวใดควรลบ แถวใดควรเก็บไว้ และแถวใดควรเก็บไว้พร้อมสร้างตัวแปรใหม่กำกับ พร้อมอธิบายว่าการใช้เกณฑ์ IQR เพียงอย่างเดียวกับข้อมูลชุดนี้จะทำให้เสียข้อมูลสำคัญอย่างไร

กรณี 8: การรวมข้อมูลจากสองระบบที่ออกแบบไม่เหมือนกัน

บริบท (Context)

บริษัทควบรวมกิจการกับอีกบริษัทหนึ่ง จึงต้องรวมฐานข้อมูลลูกค้าของทั้งสองระบบให้เป็นชุดเดียวสำหรับการวิเคราะห์

ตารางระบบ A

customer_id	signup_date	province	annual_revenue_thb	is_active
1001	2024-05-12	ขอนแก่น	480,000	1
1002	2025-01-03	อุดรธานี	1,250,000	0

ตารางระบบ B

cust_id	date_registered	region	revenue_usd	status	monthly_revenue_usd
B-77	12/05/2024	ภาคอีสาน	13,700	Active	1,141
B-78	03/01/2025	ภาคอีสาน	35,700	Inactive	2,975

❓ คำถามเฉพาะกลุ่ม

ตารางทั้งสองมีปัญหาครบทั้งสามชนิดของ Data Integration คือ schema conflict, value conflict และ redundancy ให้ระบุว่าปัญหาแต่ละชนิดอยู่ที่คอลัมน์ใด แล้วออกแบบโครงสร้างตารางผลลัพธ์ที่รวมแล้ว พร้อมระบุว่าคอลัมน์ใดควรตัดทิ้งและเพราะเหตุใด

กรณี 9: ผลตรวจทางห้องปฏิบัติการที่ขาดหายไม่เท่ากันในแต่ละกลุ่มผู้ป่วย

บริบท (Context)

ทีมวิจัยสร้างแบบจำลองทำนายการเสื่อมของไตจากข้อมูลเวชระเบียน โดยใช้ค่าผลตรวจเลือดเป็นตัวแปรหลัก

patient_id	age	severity	creatinine	egfr	albumin	follow_up_months
P-01	58	ปานกลาง	1.4	62	4.1	24
P-02	71	รุนแรง	3.8	18	(ว่าง)	3
P-03	45	เล็กน้อย	1.0	88	(ว่าง)	24
P-04	66	รุนแรง	(ว่าง)	(ว่าง)	(ว่าง)	1
P-05	52	ปานกลาง	1.6	55	3.9	24

ข้อมูลเพิ่มเติม (Key Findings)

ผู้ป่วยกลุ่มอาการเล็กน้อยมักไม่ได้รับการสั่งตรวจอัลบูมิน ส่วนผู้ป่วยกลุ่มอาการรุนแรงบางรายเสียชีวิตหรือถูกส่งต่อไปสถานพยาบาลอื่นก่อนที่จะเก็บข้อมูลได้ครบ

? คำถามเฉพาะกลุ่ม

ค่าที่ขาดหายในตารางนี้มาจากกลไกที่ต่างกันอย่างน้อยสองแบบในคอลัมน์คนละคอลัมน์ ให้ระบุให้ชัด แล้วอธิบายว่าเหตุใดการสร้าง missing indicator จึงมีประโยชน์เป็นพิเศษกับข้อมูลทางการแพทย์ชุดนี้

กรณี 10: การเตรียมตัวแปรหมวดหมู่และการเลือกรูปแบบไฟล์จัดเก็บ

บริบท (Context)

ทีมข้อมูลเตรียมชุดข้อมูลผู้สมัครงานเพื่อสร้างแบบจำลองคัดกรองเบื้องต้น และต้องส่งต่อชุดข้อมูลให้ทีมอื่นนำไปใช้ซ้ำทุกสัปดาห์

applicant_id	province	education_level	satisfaction	expected_salary	applied_positio
A-01	ขอนแก่น	ปริญญาตรี	พอใจมาก	25,000	นักวิเคราะห์ข้อมูล
A-02	กรุงเทพมหานคร	ปริญญาโท	เฉย ๆ	45,000	นักวิทยาศาสตร์ข้อมูล
A-03	อุดรธานี	มัธยมปลาย	ไม่พอใจ	15,000	เจ้าหน้าที่ธุรการ
A-04	เชียงใหม่	ปริญญาตรี	พอใจ	28,000	นักวิเคราะห์ข้อมูล

ข้อมูลเพิ่มเติม (Key Findings)

ข้อมูลจริงมีจังหวัดครบ 77 จังหวัด ตำแหน่งงานมากกว่า 400 ตำแหน่ง และมีผู้สมัครสะสมประมาณ 8 ล้านแถว ปัจจุบันทีมจัดเก็บเป็นไฟล์ CSV ไฟล์เดียว

? คำถามเฉพาะกลุ่ม

ให้จำแนกตัวแปรแต่ละตัวเป็น nominal, ordinal หรือ ratio และเลือกวิธีแปลงให้เหมาะสม พร้อมอธิบายว่าเหตุใดการทำ one-hot encoding กับคอลัมน์ตำแหน่งงานจึงอาจสร้างปัญหา และควรเปลี่ยนรูปแบบไฟล์จัดเก็บหรือไม่ เพราะเหตุใด

แนวทางและข้อสรุปการวิเคราะห์ข้อมูลรายกลุ่ม (กลุ่มที่ 1 - 10)

กลุ่มที่ 1 · MNAR (Missing Not at Random)

การไม่ตอบสัมพันธ์กับรายได้ การลบแถวจะทำให้ค่าเฉลี่ยต่ำกว่าจริง ควรใช้ตัวแปรแทน (อาชีพ/การศึกษา) เติมค่าด้วยแบบจำลองร่วมกับ missing indicator และแก้ไขที่การออกแบบสอบถามโดยใช้ช่วงรายได้

กลุ่มที่ 2 · Glitch vs Noise

ค่า -999 คือ glitch (รหัสพิเศษแทนค่าว่าง) ส่วน 4521.8 คือ noise นอกขอบเขตทางกายภาพ ข้อมูลอนุกรมเวลาควรเติมด้วยค่าใกล้เคียงตามเวลาแทนค่าเฉลี่ยรวม เพื่อป้องกันความผิดพลาดของระบบแจ้งเตือน

กลุ่มที่ 3 · Outlier & Metadata

ตรวจจับจากความสอดคล้องระหว่าง Height, Weight, BMI หรือใช้กฎช่วงค่ามนุษย์ บทเรียนสำคัญคือความเสียหายมักเกิดจากการไม่มีข้อตกลงเรื่องหน่วยวัด ดังนั้นทุกชุดข้อมูลต้องมี metadata ระบุหน่วยกำกับเสมอ

กลุ่มที่ 4 · Date/Time Formatting & Timezone

แก้ไขความกำกวมของวันที่โดยแยกแปลงตามแหล่งข้อมูลต้นทาง สำหรับ Timezone ควรแปลงทุกอย่างเป็นฐานเดียวกัน (UTC) ในชั้นจัดเก็บเพื่อป้องกันข้อผิดพลาดในการสรุปยอดขายรายวัน

กลุ่มที่ 5 · Data Deduplication & Entity Resolution

ลบแถวที่ซ้ำซ้อนโดยสมบูรณ์ และทำความสะอาดคีย์ (เบอร์โทร, อีเมล) ก่อนรวมบุคคลเดียวกัน เพื่อป้องกันปัญหายอดซื้อเฉลี่ยต่อรายต่ำกว่าความเป็นจริง โดยตั้งกฎเกณฑ์การรวมให้สมดุลไม่ตึงหรือหย่อนเกินไป

กลุ่มที่ 6 · Data Cleaning Pipeline

พบปัญหา Thai encoding, สัญลักษณ์สกุลเงิน และตัวพิมพ์ไม่สม่ำเสมอในหมวดหมู่ ลำดับการแก้ไขต้องเริ่มจาก encoding ก่อนเสมอ เพื่อไม่ให้กระทบกับการจับคู่ชื่อสินค้าและการรวมหมวดหมู่ในขั้นตอนถัดไป

กลุ่มที่ 7 · Outlier Management

ยอดขายวันแคมเปญหรือวันหยุดเป็นค่าสุดขั้วที่ถูกต้องจริง ควรเก็บไว้และสร้างตัวแปรกำกับ (เช่น is_campaign) หลีกเลี่ยงการใช้เกณฑ์ IQR ตัดทิ้งทั้งหมด เพื่อให้แบบจำลองสามารถเรียนรู้ช่วงเวลาสำคัญได้

กลุ่มที่ 8 · Schema & Value Integration

พบปัญหาขัดแย้งของชื่อคอลัมน์ ระดับข้อมูล (จังหวัด/ภูมิภาค) สกุลเงิน และรูปแบบสถานะ ตารางผลลัพธ์ควรกำหนดสกุลเงินและหน่วยเวลาเดียว โดยเก็บรายละเอียดที่ลึกที่สุดและตัดคอลัมน์ซ้ำซ้อนออก

กลุ่มที่ 9 · Clinical Data Missing Mechanisms

พบคอลัมน์ขาดหายแบบ MAR และ MNAR การสร้าง missing indicator มีประโยชน์อย่างยิ่งในการแพทย์ เนื่องจากประวัติการส่งตรวจเป็นข้อมูลเชิงคลินิกที่สะท้อนถึงการวินิจฉัยของแพทย์

กลุ่มที่ 10 · Feature Engineering & Storage

การทำ One-hot กับตำแหน่งงานที่หลากหลายจะทำให้ข้อมูลกระจัดกระจาย ควรจัดกลุ่มตามสายงานแทน และควรเปลี่ยนรูปแบบจัดเก็บจาก CSV เป็น Parquet เพื่อประสิทธิภาพการบีบอัดและรักษาชนิดข้อมูล

รู้จักไฟล์ข้อมูล

ที่ Data Scientist ใช้ประจำ — CSV · JSON · Excel · Parquet · และอื่นๆ

เลือกไฟล์ให้ถูก ทำงานให้เร็วขึ้น

Text-based · ไฟล์ที่ 1

CSV (Comma-Separated Values)



นิยม #1 ในการแชร์ข้อมูลตาราง

- ข้อความล้วน (plain text) คั่นแต่ละค่าด้วยจุลภาค
- ข้อดี: เปิดได้ทุกเครื่องมือ ไม่มี dependency, มนุษย์อ่านได้
- ข้อเสีย: ไม่เก็บ data type, ไฟล์ใหญ่กว่ารูปแบบ binary
- ไม่รองรับโครงสร้างซ้อนกัน (nested) หรือหลาย sheet

```
# ตัวอย่างโค้ด (pandas)
import pandas as pd
df = pd.read_csv("data.csv")
df.to_csv("out.csv",
          index=False)
```

Text-based · ไฟล์ที่ 2

JSON (JavaScript Object Notation)



มาตรฐานของ API และ web data

- เก็บข้อมูลแบบ key-value ซ้อนกันเป็นลำดับชั้นได้ (nested)
- ข้อดี: รองรับโครงสร้างซับซ้อน, ภาษาโปรแกรมแทบทุกตัวอ่านได้
- ข้อเสีย: ไฟล์ใหญ่กว่า CSV, แปลงเป็นตารางต้อง normalize ก่อน
- นิยมใช้รับส่งข้อมูลระหว่าง Web API กับ Data Pipeline

```
# ตัวอย่างไฟล์ JSON
{"name": "Alice",
 "scores": [88, 92]}

import pandas as pd
df = pd.read_json("d.json")
```

Text-based · ไฟล์ที่ 3

Excel (.xlsx)

มาตรฐานงานออฟฟิศและธุรกิจ

- ไฟล์ binary ของ Microsoft Excel รองรับหลาย sheet ในไฟล์เดียว
- ข้อดี: ใส่ฟอร์แมต สูตรคำนวณ และกราฟได้ ทีมธุรกิจเปิดอ่านง่าย
- ข้อเสีย: โหลดช้ากว่า CSV มาก, ไม่เหมาะกับข้อมูลขนาดใหญ่
- ต้องใช้ library เพิ่ม (openpyxl) ในการอ่าน/เขียน

```
# ตัวอย่างโค้ด (pandas)
import pandas as pd
df = pd.read_excel(
    "data.xlsx",
    sheet_name="Q1")
```

Binary & Columnar Formats
เร็วกว่า เล็กกว่า สำหรับข้อมูลใหญ่



Parquet



Pickle



HDF5 · Feather

Parquet



มาตรฐานของ Big Data ยุคปัจจุบัน

- เก็บข้อมูลแบบ columnar (เก็บทีละคอลัมน์) พร้อมบีบอัดในตัว
- ข้อดี: ไฟล์เล็กกว่า CSV มาก, อ่านเฉพาะคอลัมน์ที่ต้องการได้ (เร็วขึ้นมาก)
- เก็บ data type ไว้ครบ ไม่ต้องเดาแบบ CSV
- มาตรฐานของ Spark, Hadoop, และ data lake ทั่วไป

```
# ตัวอย่างโค้ด (pandas)
import pandas as pd
df = pd.read_parquet(
    "data.parquet")
df.to_parquet(
    "out.parquet")
```

Binary/Columnar · ไฟล์ที่ 2

Pickle (.pkl)



เก็บ Python object ได้ทุกชนิด

- Serialize object ของ Python (list, dict, model, DataFrame)
- นิยมใช้บันทึกโมเดล ML ที่เทรนแล้ว (.pkl)
- เปิดได้เร็วมาก เพราะไม่ต้องแปลง type กลับ



ข้อควรระวัง

- อ่านได้เฉพาะ Python เท่านั้น ภาษาอื่นเปิดไม่ได้
- ห้ามเปิดไฟล์ pickle จากแหล่งที่ไม่น่าเชื่อถือ (security risk)
- เวอร์ชัน Python/library ต่างกัน อาจเปิดไม่ได้

HDF5 และ Feather



HDF5 (.h5)

- เก็บข้อมูลขนาดใหญ่มาก (multi-GB) แบบ hierarchical
- นิยมในงาน scientific computing และ deep learning (เก็บ array/tensor)
- อ่านข้อมูลเฉพาะบางส่วนได้ โดยไม่ต้องโหลดทั้งไฟล์



Feather (.feather)

- ออกแบบมาเพื่อความเร็วในการอ่าน/เขียนสูงสุด
- ใช้แลกข้อมูลระหว่าง pandas (Python) กับ R ได้ไร้รอยต่อ
- เหมาะกับงานที่ต้องเซฟ/โหลด DataFrame ซ้ำๆ ระหว่างพัฒนา

สรุป

เปรียบเทียบไฟล์ทั้งหมด

CSV

เล็ก-กลาง · มนุษย์อ่านได้ · ไม่เก็บ type · ตารางเดียว

JSON

เล็ก-กลาง · โครงสร้างซ้อนได้ · มาตรฐาน API

Parquet

ใหญ่ · เร็ว · เก็บ type ครบ · มาตรฐาน Big Data

Pickle / HDF5 / Feather

เฉพาะกิจ: เก็บโมเดล ML, array ขนาดใหญ่, หรือสลับ R↔Python

เลือกให้ถูก

เลือกไฟล์แบบไหน เมื่อไหร่ ?

แชร์ให้คนอื่นเปิดง่าย

ใช้ CSV — เปิดได้ทุกที่ ไม่ต้องลง library พิเศษ

ข้อมูลซ้อนกันเป็นลำดับชั้น

ใช้ JSON — รองรับ nested structure ได้ดีที่สุด

ข้อมูลใหญ่ระดับ GB ขึ้นไป

ใช้ Parquet — เร็ว เล็ก เก็บ type ครบ

ต้องเซฟ /โหลดโมเดลหรือ object ของ Python

ใช้ Pickle — เก็บ Python object ได้ทุกชนิด